



YZM0101

Yapay Zeka ve Makine Öğrenimine

Giriş

Hafta 9

Denetimli Öğrenme: Regresyon

Sayısal Değerleri Tahmin Etmek

- Geçen hafta: Makine öğrenmesine genel giriş.
- Bu hafta: İlk somut modelimiz - Lineer Regresyon.
- Regresyon: Girdi değişkenlerine (özellikler) dayanarak sürekli bir çıktı değişkenini (hedef) tahmin etme görevidir.
- Amaç: Veri noktaları arasındaki temel ilişkiyi modelleyen bir fonksiyon bulmak.

Basit Lineer Regresyon

Veriye Bir Çizgi Çekmek


- Tek bir girdi özelliği (x) ve tek bir çıktı hedefi (y) arasındaki ilişkiyi modeller.
- Model, bir doğru denklemdir: $y = mx + b$
- - **y**: Tahmin edilen değer (dependent variable).
- - **x**: Girdi özelliği (independent variable).
- - **m (slope)**: Eğimi. x'teki bir birimlik artışın y'yi ne kadar değiştirdiğini gösterir.
- - **b (intercept)**: Kesişim noktası. x sıfır iken y'nin aldığı değer.
- **Öğrenme Görevi**: Veriye en uygun 'm' ve 'b' değerlerini bulmaktır.

Soru

- Aşağıdaki veri noktalarını göz önünde bulundurun:
- Bu veriye en uygun doğruyu ($y = m x + b$) bulun.
- Bulduğunuz doğrunun grafiğini veri noktalarıyla birlikte çizdirin.
- 6 saat çalışan bir öğrencinin notunu tahmin edin.

Çalışma Saati (x)	Sınav Notu (y)
1	52
2	57
3	63
4	71
5	75

-
- Eğim (m): 6.0
 - Kesişim (b): 45.6



Maliyet Fonksiyonu (Cost Function)

Modelimiz Ne Kadar Kötü?


- Bir doğrunun verilere ne kadar 'uygun' olduğunu nasıl ölçeriz?
- Her bir veri noktası için, modelin tahmin ettiği değer (çizgi üzerindeki nokta) ile gerçek değer arasındaki hatayı (error) hesaplarız.
- **Maliyet Fonksiyonu (J):** Bu hataların ortalamasını alan bir fonksiyondur.
- **Ortalama Kare Hata (Mean Squared Error - MSE):** En yaygın kullanılan maliyet fonksiyonudur. Hataların karelerini alarak negatif değerleri ortadan kaldırır ve büyük hataları daha fazla cezalandırır.

Ortalama Kare Hata (MSE)

$$J(m, b) = MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

MSE Görselleřtirmesi

MSE = 46.03



Gradyan Azalması (Gradient Descent)

Hata Yüzeyinde En Dibe İnme

- Maliyet fonksiyonu $J(m, b)$ 'yi minimize eden m ve b değerlerini bulmak için kullanılan bir optimizasyon algoritmasıdır.
- **Analoji:** Gözleri bağlı bir şekilde bir vadinin yamacında duruyorsunuz ve en alçak noktayı bulmaya çalışıyorsunuz.
- **Strateji:** Bulduğunuz noktadaki en dik iniş yönünü (gradyanın tersi) bulun ve o yönde küçük bir adım atın. Bu süreci, dibe ulaşana kadar tekrarlayın.

$$J(m, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (mx_i + b))^2$$

$$J(m, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (mx_i + b))^2$$

$$\frac{\partial J}{\partial m} = \frac{-2}{n} \sum_{i=1}^n x_i (y_i - (mx_i + b))$$

$$J(m, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (mx_i + b))^2$$

$$\frac{\partial J}{\partial m} = \frac{-2}{n} \sum_{i=1}^n x_i (y_i - (mx_i + b))$$

$$\frac{\partial J}{\partial b} = \frac{-2}{n} \sum_{i=1}^n (y_i - (mx_i + b))$$

Gradyan Azalması Algoritması

Parametreleri Güncellemek

- 1. m ve b için rastgele başlangıç değerleri seç.
- 2. Döngü (yakınsayana kadar):
 - a. Mevcut m ve b değerleri için maliyet fonksiyonunun gradyanını (türevini) hesapla.
 - - Gradyan, her parametreye göre alınan kısmi türevlerden oluşan bir vektördür.
 - - Bize en dik 'yokuşun' yönünü söyler.
 - b. Parametreleri, gradyanın tersi yönde, küçük bir adımla güncelle:
 - - $\hat{m} = m - \alpha * (J'nin\ m'e\ göre\ türevi)$
 - - $\hat{b} = b - \alpha * (J'nin\ b'ye\ göre\ türevi)$
 - - **α (alfa):** Öğrenme Oranı (Learning Rate). Adım büyüklüğünü kontrol eder.

initialize m, b randomly
repeat until convergence:

1. Tahminleri hesapla
 $y_{\text{pred}} = m * x + b$

2. Hataları bul
 $\text{error} = y_{\text{pred}} - y$

3. Gradyanları hesapla
 $dm = (2/n) * \Sigma(\text{error} * x)$
 $db = (2/n) * \Sigma(\text{error})$

4. Parametreleri güncelle
 $m = m - \alpha * dm$
 $b = b - \alpha * db$

return m, b

Çoklu Lineer Regresyon

Birden Fazla Girdi Özelliği

- Gerçek dünya problemleri genellikle birden fazla özelliğe sahiptir.
- Örnek: Bir evin fiyatı sadece metrekaresine değil, aynı zamanda oda sayısına, yaşına, konumuna vb. de bağlıdır.
- Model denklemi genişler:
- $y = b + m_1 * x_1 + m_2 * x_2 + ... + m_n * x_n$
- - $x_1, x_2, ...$: Farklı girdi özellikleri.
- - $m_1, m_2, ...$: Her bir özelliğin ağırlığı (katsayısı).
- Gradyan Azalması fikri tamamen aynı kalır, sadece daha fazla parametre ($b, m_1, m_2, ...$) için gradyan hesaplanır.

Polinomsal Regresyon

Doğrusal Olmayan İlişkileri Modelleme

- Veri noktaları her zaman düz bir çizgi üzerinde olmayabilir.
- **Fikir:** Mevcut özellikleri kullanarak yeni polinom özellikler (x^2 , x^3 , $x_1 * x_2$, vb.) yaratmak ve bu yeni özellikler üzerinde bir lineer regresyon modeli eğitmek.
- Model denklemi bir polinom olur:
- $y = b + m_1 * x + m_2 * x^2 + \dots$
- Bu, aslında hala bir 'lineer' modeldir, çünkü katsayılarına (m) göre lineerdir

Aşırı Öğrenme ve Regresyon

Çok Karmaşık Modellerin Tehlikesi

- Polinomsal regresyonda polinomun derecesini çok fazla artırmak, aşırı öğrenmeye (overfitting) yol açabilir.
- Model, eğitim verisindeki gürültüye bile uyan aşırı karmaşık bir eğri öğrenir.
- **Çözüm: Düzenleştirme (Regularization)**
 - - Modelin katsayılarının (m 'lerin) çok büyük değerler almasını engelleyerek modeli 'basit' tutmaya zorlayan bir tekniktir.
 - - Maliyet fonksiyonuna, katsayıların büyüklüğünü ölçen bir 'ceza' terimi eklenir.
 - - **Ridge (L2) ve Lasso (L1) Regresyonu** en yaygın türleridir.

Haftanın Kavramları: Özet

Akılda Kalması Gerekenler

- **Lineer Regresyon:** Girdi ve çıktı arasındaki doğrusal ilişkiyi $y = mx + b$ gibi bir doğruyla modeller.
- **Maliyet Fonksiyonu (MSE):** Modelin tahminleri ile gerçek değerler arasındaki ortalama kare hatayı ölçer. Amacımız bunu minimize etmektir.
- **Gradyan Azalması:** Maliyet fonksiyonunu minimize etmek için modelin parametrelerini (m, b) iteratif olarak güncelleyen bir optimizasyon algoritmasıdır.
- **Öğrenme Oranı (α):** Gradyan Azalması'ndaki adım büyüklüğünü kontrol eden bir hiperparametredir.
- **Düzenleştirme (Regularization):** Aşırı öğrenmeyi önlemek için modelin karmaşıklığını (katsayıların büyüklüğünü) cezalandıran bir tekniktir.

Gelecek Hafta: Denetimli Öğrenme - Sınıflandırma

Teorik Dersin Konusu

- Regresyondan sınıflandırmaya geçiş.
- Lojistik Regresyon: Lineer bir modeli, olasılık tahmini yapan bir sınıflandırıcıya nasıl dönüştürürüz? (Sigmoid Fonksiyonu).
- K-En Yakın Komşu (K-Nearest Neighbors - KNN): En basit sınıflandırma algoritması. 'Bana arkadaşlarını söyle, sana kim olduğunu söyleyeyim.'
- Model Değerlendirme Metrikleri: Doğruluk (Accuracy) neden her zaman yeterli değildir? (Precision, Recall, F1-Score).

Düşünme Sorusu: Öğrenme Oranı (α)

Gradyan Azalmasının Adım Büyüklüğü

- Gradyan Azalması algoritmasında öğrenme oranı (α) çok önemlidir.
- 1. Eğer α 'yı **çok küçük** seçersek ne olur? Algoritmanın performansı nasıl etkilenir?
- 2. Eğer α 'yı **çok büyük** seçersek ne olur? Algoritmanın davranışı nasıl olur ve neden bir çözüme ulaşamayabilir?
- Doğru öğrenme oranını bulmak neden bir 'deneme-yanılma' sürecidir?

Gerçek Dünya Örneği: Ekonomik Tahminler

Regresyonun Gücü

- Ekonomistler ve finansal analistler, gelecekteki ekonomik göstergeleri tahmin etmek için yaygın olarak regresyon modellerini kullanır.
- **Problem:** Bir ülkenin bir sonraki yılki Gayri Safi Yurt İçi Hasılasını (GSYİH) tahmin etmek.
- **Özellikler (Girdiler):** Enflasyon oranı, işsizlik oranı, faiz oranları, ihracat miktarı, vb.
- **Hedef (Çıktı):** GSYİH büyüme oranı.
- Modelin katsayıları ($m_1, m_2, \dots$), her bir faktörün ekonomi üzerindeki etkisinin büyüklüğünü ve yönünü yorumlamak için kullanılabilir.

Önemli Not: Korelasyon Nedensellik Değildir!

Regresyonun Yanlış Yorumlanması

- Regresyon modelleri, değişkenler arasındaki **korelasyonu (ilişkiyi)** bulur.
- Ancak, bir değişkenin diğerine **neden olduğunu** kanıtlamaz.
- **Örnek:** Yaz aylarında hem dondurma satışları hem de boğulma vakaları artar. Bu iki değişken arasında güçlü bir pozitif korelasyon vardır.
- **Sonuç:** Dondurma yemek boğulmaya neden olmaz! Her ikisine de neden olan gizli bir faktör (sıcak hava) vardır.
- Model sonuçlarını yorumlarken dikkatli olunmalıdır.

Özet: Makine Öğrenmesi Felsefesi

Genelleme Sanatı

- Makine öğrenmesinin temel amacı, geçmiş verilerden öğrenerek, gelecekteki görünmeyen veriler hakkında **doğru genellemeler** yapabilen modeller oluşturmaktır.
- Bu süreç, 'ezberleme' (overfitting) ve 'yetersiz kalma' (underfitting) arasındaki hassas dengeyi bulmayı gerektirir.
- Başarı, sadece iyi bir algoritmaya değil, aynı zamanda kaliteli veriye, akıllı özellik mühendisliğine ve doğru değerlendirme metriklerine de bağlıdır.



• Sorular