



YZM0101

Yapay Zeka ve Makine Öğrenimine

Giriş

Hafta 10

Denetimli Öğrenme: Sınıflandırma


Kategorik Değerleri Tahmin Etmek

- Geçen hafta: Regresyon ile sürekli değerleri tahmin ettik.
- Bu hafta: Sınıflandırma ile kategorik etiketleri tahmin edeceğiz.
- Sınıflandırma: Girdi değişkenlerine dayanarak bir ögenin hangi sınıfa ait olduğunu belirleme görevidir.
- Örnekler: E-posta spam mı, değil mi? Bir tümör iyi huylu mu, kötü huylu mu?

Neden Lineer Regresyon Sınıflandırma İçin Kötü Bir Fikir?

Doğru Aracı Seçmek


- Sınıf etiketlerini sayılarla (0, 1) temsil edip lineer regresyon uygulayabilir miyiz?
- **Sorun 1:** Model, 0'dan küçük veya 1'den büyük değerler üretebilir, bu da anlamsızdır.
- **Sorun 2:** Karar eşiği (threshold) aykırı değerlere karşı çok hassastır. Yeni bir veri noktası, tüm karar sınırını önemli ölçüde kaydırabilir.
- **Sonuç:** Lineer regresyon, sınıflandırma problemlerinin doğasına uygun değildir.



Lojistik Regresyon

Lineer Modelden Olasılığa

- Lojistik Regresyon, adında 'regresyon' olmasına rağmen bir **sınıflandırma** algoritmasıdır.
- **Ana Fikir:** Lineer regresyonun çıktısını, 0 ile 1 arasında değerler üreten özel bir fonksiyondan geçirmek.
- Bu fonksiyon **Sigmoid (veya Lojistik) Fonksiyonu**'dur.
- Çıktı, bir örneğin pozitif sınıfa (sınıf 1) ait olma **olasılığı** olarak yorumlanabilir.



Karar Sınırı (Decision Boundary)

Sınıfları Ayıran Çizgi

- Sigmoid fonksiyonunun çıktısını (olasılığı) bir sınıfa nasıl dönüştürürüz?
- Bir eşik değer (threshold) belirleriz, genellikle 0.5.
- Eğer $P(y=1|x) \geq 0.5$ ise, örneği sınıf 1 olarak tahmin et.
- Eğer $P(y=1|x) < 0.5$ ise, örneği sınıf 0 olarak tahmin et.
- Modelin tam olarak 0.5 olasılık ürettiği noktaların oluşturduğu çizgiye veya yüzeye Karar Sınırı denir.
- Lojistik regresyonda karar sınırı **doğrusaldır**.

Lojistik Regresyon İçin Maliyet Fonksiyonu

Yeni Bir Hata Ölçümü

- Lineer regresyondaki MSE (Ortalama Kare Hata) maliyet fonksiyonunu burada kullanabilir miyiz?
- **Hayır.** Sigmoid fonksiyonu nedeniyle, MSE kullanırsak maliyet fonksiyonu 'dışbükey olmayan' (non-convex) bir hal alır. Bu, Gradyan Azalması'nın yerel minimumlara takılıp kalmasına neden olabilir.
- **Çözüm: Logaritmik Kayıp (Log Loss) veya Çapraz Entropi Kaybı (Cross-Entropy Loss)** adı verilen yeni bir maliyet fonksiyonu kullanılır.
- Bu fonksiyon, modelin yanlış tahminlerine (özellikle emin olduğu yanlış tahminlere) büyük bir ceza verir.


$$-\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$

Binary Cross-Entropy / Log Loss

K-En Yakın Komşu (K-Nearest Neighbors - KNN)

Tembel Öğrenme

- KNN, son derece basit ve sezgisel bir sınıflandırma (ve regresyon) algoritmasıdır.
- **Felsefe:** 'Bana arkadaşlarını söyle, sana kim olduğunu söyleyeyim.'
- **Öğrenme Aşaması:** Yok! KNN, tüm eğitim verisini sadece hafızasında saklar. Bu yüzden 'tembel' bir algoritma olarak adlandırılır.
- **Tahmin Aşaması:** Yeni bir veri noktası geldiğinde, ona en yakın 'K' adet komşusunu bulur ve bu komşuların çoğunluğunun ait olduğu sınıfı o noktaya atar.



KNN: K Değerini Seçmek ve Mesafe Ölçümü

Algoritmanın Ayarlanması

- **K Değeri:** Algoritmanın en önemli hiperparametresidir.
- - **Küçük K:** Gürültüye karşı hassas, karmaşık karar sınırları (overfitting riski).
- - **Büyük K:** Daha pürüzsüz karar sınırları, ancak sınıflar arasındaki ince detayları kaçırabilir (underfitting riski).
- - Genellikle tek bir sayı seçilir (beraberliği önlemek için).
- **Mesafe Ölçümü:** 'Yakınlığı' nasıl tanımlarız?
- - **Öklid Mesafesi:** En yaygın kullanılan, iki nokta arasındaki düz çizgi mesafesi.
- - **Manhattan Mesafesi:** Şehir bloklarında yürür gibi, eksenler boyunca alınan toplam mesafe.

Model Değerlendirme Metrikleri

Doğruluk (Accuracy) Neden Yeterli Değil?

- **Doğruluk:** (Doğru Tahmin Sayısı) / (Toplam Tahmin Sayısı).
- **Problem:** Dengesiz Veri Setleri (Imbalanced Datasets)
 - - Örnek: Bir hastalığın toplumda %1 oranında görüldüğü bir veri seti düşünün.
 - - Modelimiz her zaman 'hasta değil' tahmini yaparsa, doğruluğu %99 olur!
 - - Ancak bu model, hiçbir hastayı tespit edemediği için tamamen işe yaramazdır.
- **Çözüm:** Sadece doğruluğa bakmak yerine daha anlamlı metrikler kullanmak.

Karmaşıklık Matrisi (Confusion Matrix)

Tahminlerin Detaylı Dökümü

- Modelin performansını görselleştiren bir tablodur.
- **Gerçek Pozitif (TP):** Gerçekte pozitif, tahminde pozitif.
- **Gerçek Negatif (TN):** Gerçekte negatif, tahminde negatif.
- **Yanlış Pozitif (FP - Tip 1 Hata):** Gerçekte negatif, tahminde pozitif.
(Sağlıklı kişiye 'hasta' demek).
- **Yanlış Negatif (FN - Tip 2 Hata):** Gerçekte pozitif, tahminde negatif.
(Hasta kişiye 'sağlıklı' demek).

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Precision ve Recall

Farklı Hata Türlerine Odaklanmak

- **Precision (Kesinlik):** Pozitif olarak tahmin ettiklerimizin ne kadarı gerçekten pozitif?
 - - $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$
 - - **Amacı:** Yanlış Pozitif (FP) sayısını minimize etmek. (Spam filtresi: Normal bir maili spam klasörüne atmamak önemlidir).
- **Recall (Duyarlılık veya Hassasiyet):** Gerçekte pozitif olanların ne kadarını doğru tespit edebildik?
 - - $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
 - - **Amacı:** Yanlış Negatif (FN) sayısını minimize etmek. (Hastalık teşhisi: Hasta birini gözden kaçırmamak önemlidir).

F1 Skoru: Precision ve Recall'un Dengesi

Tek Bir Metrikte Birleştirmek

- Precision ve Recall arasında genellikle bir **takas (trade-off)** vardır. Birini artırmaya çalışırken diğeri düşebilir.
- **F1 Skoru:** Precision ve Recall'un **harmonik ortalamasıdır**.
- - $F1 = 2 * (Precision * Recall) / (Precision + Recall)$
- - Bu iki metriği dengeli bir şekilde tek bir skorda birleştirir.
- - Dengesiz sınıflara sahip problemler için doğruluktan çok daha iyi bir genel performans ölçütüdür.

ROC ve PR Eğrileri + AUC Kıyaslaması



Sınıflandırıcı Performansını Görsel Analiz Etmek

- ROC (Receiver Operating Characteristic) eğrisi: Doğru Pozitif Oranı (TPR) ile Yanlış Pozitif Oranı (FPR) arasındaki ilişkiyi gösterir.
- PR (Precision–Recall) eğrisi: Precision ve Recall arasındaki dengeyi görselleştirir.
- AUC (Area Under Curve): Eğrinin altındaki alan; modelin genel ayırım gücünü ölçer.
- ROC, dengeli sınıflarda yararlıdır; PR, dengesiz sınıflarda daha bilgilendiricidir.

Actual	0	TN	FP
	1	FN	TP
		0	1
		Predicted	

$$\text{False Positive Rate (FPR)} = \frac{FP}{(FP + TN)}$$

$$\text{True Positive Rate (TPR)} = \frac{TP}{(TP + FN)}$$



Sınıf Dengesizliğinde PR Eğrilerinin Önemi


Gerçek Performansı Doğru Ölçmek

- Dengesiz veri setlerinde pozitif sınıfın oranı çok düşüktür (örneğin %1 dolandırıcılık).
- ROC eğrisi, yanlış pozitiflerin etkisini abartısız gösterdiği için yanıltıcı biçimde yüksek AUC verebilir.
- PR eğrisi, azınlık sınıf performansını doğrudan ölçer ve gerçek başarıyı yansıtır.
- Baseline (referans) precision, pozitif sınıf oranına eşittir – bu çizginin üzerindeki alan modelin gerçek kazancını gösterir.

Eşik (Threshold) Ayarı

Doğru Noktayı Seçmek

- Sınıflandırıcılar genellikle bir olasılık değeri üretir; bu değer 0.5 eşik alınarak sınıf kararı verilir.
- Bu eşik, problem türüne göre ayarlanabilir: hatalı pozitif/negatif maliyetine göre optimum değer seçilir.
- F1 skoru gibi metriklerle en uygun eşiği bulmak mümkündür.
- Eşik ayarı, ROC veya PR eğrisi üzerinde maksimum denge noktasına karşılık gelir.



KNN Hiperparametre Analizi

K, Mesafe ve Ölçekleme Etkisi

- KNN, tahmin yaparken en yakın k komşunun etiketlerine göre karar verir.
- K küçükse model yüksek varyanslı; K büyükse yüksek bias'lı olur.
- Mesafe metriği (Euclidean, Manhattan) ve özellik ölçeklemesi sonuçları önemli ölçüde etkiler.
- Optimal K değeri, doğrulama eğrileri veya çapraz doğrulama ile belirlenir.

Confusion Matrix Vaka Analizi

Yanlış Sınıflandırmaların Etkisini Anlamak

- Confusion matrix, modelin tahmin sonuçlarını dört kategoriye ayırır: TP, FP, FN, TN.
- Bu tablo üzerinden precision, recall, specificity gibi metrikler hesaplanır.
- Gerçek dünya örneği: Hastalık taramasında yüksek FP yanlış alarm; yüksek FN kaçan vakadır.
- Analiz: Problemin doğasına göre hangi hata türünün daha kritik olduğuna karar verilmelidir.

		Predicted	
		Spam	Non-spam
Actual	Spam	600 (True positive)	300 (False negative)
	Non-spam	100 (False positive)	9000 (True negative)



Model Kalibrasyonu

Olasılık Tahminlerinin Gerçekçi Olması

- Bazı modeller (örneğin SVM) olasılıkları doğrudan üretmez veya kötü kalibre eder.
- Kalibrasyon, tahmin olasılıklarını gerçek gözlemlenme oranlarıyla hizalar.
- Platt Scaling veya Isotonic Regression yaygın kalibrasyon yöntemleridir.
- İyi kalibre edilmiş modeller, ROC–PR metriklerinden bağımsız olarak güvenilir olasılık tahmini sağlar.

Haftanın Kavramları: Özet

Akılda Kalması Gerekenler

- **Sınıflandırma:** Bir öğeyi önceden tanımlanmış kategorilere atama görevi.
- **Lojistik Regresyon:** Çıktısı 0-1 arasında bir olasılık olan, doğrusal bir sınıflandırma modeli.
- **Karar Sınırı:** Modelin farklı sınıflar arasında karar verdiği ayırıcı çizgi/yüzey.
- **KNN:** Tüm eğitim verisini hafızada tutan ve en yakın komşuların oyuna göre karar veren 'tembel' bir algoritma.
- **Karmaşıklık Matrisi:** Modelin TP, TN, FP, FN sayılarını gösteren ve performans analizinin temelini oluşturan tablo.
- **Precision, Recall, F1-Skoru:** Dengesiz veri setlerinde doğruluktan daha anlamlı olan ve farklı hata türlerine odaklanan değerlendirme metrikleri.

Gelecek Hafta: Karar Ağaçları ve SVM

Teorik Dersin Konusu

- Karar Ağaçları: İnsanların karar verme sürecine çok benzeyen, yorumlanması kolay, akış şeması benzeri modeller.
- Rastgele Ormanlar (Random Forests): Birçok karar ağacını birleştirerek daha güçlü ve stabil modeller oluşturma (Topluluk Öğrenmesi).
- Destek Vektör Makineleri (SVM): Sınıflar arasındaki 'marjini' maksimize ederek en iyi karar sınırını bulmaya odaklanan güçlü bir algoritma.

Düşünme Sorusu: Hangi Hata Daha Kötü?

Yanlış Pozitif mi, Yanlış Negatif mi?

- Aşağıdaki iki senaryoyu düşünün:
- **Senaryo A: E-posta Spam Filtresi**
 - - **FP Hatası:** Önemli bir iş teklifi maili spam klasörüne düşer.
 - - **FN Hatası:** Gelen kutunuza bir reklam maili düşer.
- **Senaryo B: Kanser Teşhis Modeli**
 - - **FP Hatası:** Sağlıklı bir hastaya 'kanser olabilirsiniz, ek testler gerekiyor' denir.
 - - **FN Hatası:** Kanserli bir hastaya 'tamamen sağlıklısın' denir.
- Bu senaryolarda hangi hata türü daha maliyetlidir? Bu durum, modelimizi geliştirirken Precision'a mı yoksa Recall'a mı daha fazla önem vermemiz gerektiğini nasıl etkiler?

Gerçek Dünya Örneği: Kredi Skoru

Sınıflandırmanın Finanstaki Rolü

- Bankalar ve finans kuruluşları, bir müşterinin kredisini zamanında geri ödeyip ödemeyeceğini tahmin etmek için sınıflandırma modelleri kullanır.
- **Problem:** Bir kredi başvurusunu 'onayla' (düşük risk) veya 'reddet' (yüksek risk) olarak sınıflandırmak.
- **Özellikler (Girdiler):** Müşterinin yaşı, geliri, mevcut borçları, kredi geçmişi, mesleği vb.
- **Hedef (Çıktı):** Kredi temerrüdü (default) (Evet/Hayır).
- Bu modellerde, özellikle Yanlış Pozitif (kötü bir müşteriye onaylamak) hatasını minimize etmek kritik öneme sahiptir.

Önemli Not: Özellik Ölçeklendirme (Feature Scaling)

KNN ve Gradyan Tabanlı Modeller İçin Kritik Adım

- Eğer veri setindeki özellikler çok farklı ölçeklerdeyse (örn: yaş 20-70, maaş 5000-50000), bazı algoritmalar yanlış çalışabilir.
- **KNN**: Mesafe hesaplamaları, büyük ölçekli özellikler tarafından domine edilir. Maaştaki bir fark, yaştaki bir farktan çok daha önemli hale gelir.
- **Lojistik Regresyon (ve diğer gradyan tabanlı modeller)**: Gradyan Azalması'nın yakınsaması çok yavaşlayabilir veya zorlaşabilir.
- **Çözüm**: Tüm özellikleri benzer bir ölçeğe getirmek (örn: 0-1 arasına veya ortalaması 0, standart sapması 1 olacak şekilde). Buna **Özellik Ölçeklendirme** denir



• Sorular