

Modern Vektör Veritabanı (VectorDB) ve Anlamsal Arama Sistemi

1. Giriş

Bu projede, Python kullanılarak anahtar kelime eşleşmesi yerine anlamsal benzerlik (embedding) teknolojisini temel alan yüksek performanslı bir vektör veritabanı sistemi geliştirilmiştir. Geleneksel arama motorlarının aksine, bu sistem kelimelerin matematiksel vektör değerlerini karşılaştırarak kullanıcıya en yakın anlamdaki sonuçları sunar.

2. Sistem Tasarımı

Sistem üç temel katmandan oluşmaktadır:

- Embedding (Vektörleştirme):** Metinleri sayısal verilere dönüştüren gelişmiş dil modelleri kullanılmıştır.
- İndeksleme:** Milyonlarca veri arasında hızlı arama yapabilmek için FAISS HNSW (Hierarchical Navigable Small World) algoritması tercih edilmiştir.
- Arama Metriği:** Vektörler arasındaki anlamsal yakınlığı ölçmek için Kosinüs Benzerliği (Cosine Similarity) yöntemi uygulanmıştır.

3. Veri Seti Yapısı

Veriler JSONL formatında organize edilmiştir. Bu yapı, büyük veri setlerinin bellek dostu bir şekilde işlenmesini sağlar. Veri seti; BTÜ, Bursa ulaşım ağları, dil ve kültürün önemi ve spor gibi konuları kapsamaktadır.

4. Performans Analizi

Doküman Sayısı	Arama Süresi (ms)
25	22 ms
50	30 ms
100	48 ms

Yapılan testler, sistemin veri boyutu arttığında bile milisaniyeler düzeyinde sonuç döndürerek ölçeklenebilir olduğunu göstermiştir.

5. Örnek Senaryolar

- **Sorgu:** "Yapay zeka nedir?"
Sistem: Makine öğrenmesi, derin öğrenme ve vektör veritabanlarının çalışma mantığına dair en alakalı dokümanları getirir.
- **Sorgu:** "Bursa Teknik Üniversitesi hakkında"
Sistem: BTÜ, 2010 yılında kurulan Türkiye'nin ikinci teknik üniversitesidir. Mühendislik ve Doğa Bilimleri ağırlıklıdır.
- **Sorgu:** "Dil nedir?"
Sistem: Dil, kültürün bir parçasıdır ve dil öğrenmek, o kültürü anlamaya yardımcı olur.

6. Sonuç

Bu çalışma, modern anlamsal arama teknolojileri için güvenilir bir prototip sunmaktadır. Sistem, kelimelerin birebir eşleşmesi yerine anlamına göre sonuç üretmektedir.