



YZM0101

Yapay Zeka ve Makine Öğrenimine

Giriş

Hafta 8

Makine Öğrenmesine Giriş

Veriden Öğrenen Programlar

- Geçen hafta: Kuralları ve bilgiyi elle kodladığımız Mantıksal Ajanlar.
- Bu hafta: Kuralları veriden kendi kendine çıkaran sistemlere geçiş.
- **Arthur Samuel (1959):** 'Makine Öğrenmesi, bilgisayarlara açıkça programlanmadan öğrenme yeteneği kazandıran bir çalışma alanıdır.'
- **Temel Fikir:** Programcı kuralları yazmaz, program veri ve çıktılarından kuralları öğrenir

Neden Makine Öğrenmesi?

Geleneksel Programlamanın Yetersiz Kaldığı Yerler

- **Karmaşık Problemler:** Kurallarını elle yazmanın çok zor veya imkansız olduğu problemler (örn: yüz tanıma, konuşma anlama).
- **Değişen Ortamlar:** Sürekli yeni verilere adapte olması gereken sistemler (örn: spam filtresi, öneri sistemleri).
- **Kişiselleştirme:** Her kullanıcı için farklı kurallar gerektiren uygulamalar (örn: Netflix film önerileri).
- **İnsan Uzmanlığının Olmadığı Alanlar:** Büyük veri setlerindeki gizli desenleri ve içgörülerini keşfetme (örn: genetik analiz, borsa tahmini).

Makine Öğrenmesi Türleri

Üç Ana Paradigma

- **1. Denetimli Öğrenme (Supervised Learning):**

- - Algoritmaya etiketli veri (soru-cevap çiftleri) verilir.
- - Amaç, yeni girdiler için doğru çıktıyı tahmin etmeyi öğrenmektir.

- **2. Denetimsiz Öğrenme (Unsupervised Learning):**

- - Algoritmaya etiketsiz veri verilir.
- - Amaç, verinin içindeki gizli yapıları veya desenleri keşfetmektir.

- **3. Pekiştirmeli Öğrenme (Reinforcement Learning):**

- - Ajan, bir ortamda deneme-yanılma yoluyla hareket eder.
- - Amaç, ödülleri maksimize eden bir davranış politikası öğrenmektir.

Denetimli Öğrenme: Regresyon ve Sınıflandırma

İki Temel Görev

- **Sınıflandırma (Classification):**

- - Çıktı, **ayrık** bir kategoridir.
- - Amaç, bir girdiyi önceden tanımlanmış sınıflardan birine atamaktır.
- - Örnekler: Spam tespiti (spam/spam değil), görüntü tanıma (kedi/köpek/at), tıbbi teşhis (hasta/sağlıklı).


- **Regresyon (Regression):**

- - Çıktı, **sürekli** bir sayıdır.
- - Amaç, bir girdi için sayısal bir değer tahmin etmektir.
- - Örnekler: Ev fiyatı tahmini, hava sıcaklığı tahmini, borsa değeri tahmini.

SUPERVISED LEARNING



CLASSIFICATION



Predicting Categories
(Discrete)

REGRESSION



Predicting Values
(Continuous)



Linear
Regression



Logistic
Regression



Decision
Trees



SVM

Denetimsiz Öğrenme

Etiket Olmadan Yapı Keşfetmek


- Denetimsiz öğrenmede model, giriş verisinde doğal desenleri, grupları veya gizli yapıları bulmaya çalışır.
- Verilerde önceden tanımlanmış etiketler (çıktılar) yoktur.
- Amaç: Benzer özellikteki örnekleri gruplayarak (**kümeleme**) veya boyutu azaltarak (**özellik çıkarımı**) veri içindeki düzeni ortaya çıkarmaktır.
- Temel teknikler:
 - - K-Means, Hierarchical Clustering, DBSCAN (kümeleme)
 - - PCA, t-SNE (boyut indirgeme)

UNSUPERVISED LEARNING




**INPUT:
UNLABELED DATA**

CLUSTERING



FINDING PATTERNS



**DIMENSIONALITY
REDUCTION**

SIMPLIFYING COMPLEXITY

K-MEANS

PCA

APRIORI

ANOMOLY DETECTION

Pekiştirmeli Öğrenme

Deneme-Yanılma ile Karar Öğrenme

- Bir ajan, çevreyle etkileşime girerek eylemlerinin sonuçlarını gözlemler.
- Amaç: Toplam ödülü (**cumulative reward**) en büyükleyecek bir politika (**policy**) öğrenmek.
- Ajan – Çevre – Ödül üçlüsü temel yapıyı oluşturur.
- Temel kavramlar:
 - - Durum (**state**), Eylem (**action**), Ödül (**reward**)
 - - Politika (π): her durumda hangi eylemin seçileceğini belirleyen strateji
 - - Q-değerleri (**aksiyon-değer fonksiyonu**): belirli bir durumda belirli bir eylemin uzun vadeli getirisi

REINFORCEMENT LEARNING

CONCEPT



TRIAL AND ERROR
MAXIMIZING REWARDS



TRIAL AND ERROR



AGENT

CLUSTERING
FINDING PATTERNS

K-Means

PCA

Anomaly Detection

EXPLORATION
vs
EXPLOITATION




DIMENSIONALITY
REDUCTION

Bir Makine Öğrenmesi Projesinin Yaşam Döngüsü

Adım Adım Model Geliştirme

- **1. Problemi Tanımlama:** Ne tür bir problem çözüyoruz (sınıflandırma/regresyon)? Başarıyı nasıl ölçeceğiz?
- **2. Veri Toplama ve Hazırlama:** En önemli ve en çok zaman alan adım. Veriyi temizleme, formatlama, özellik mühendisliği.
- **3. Model Seçimi:** Probleme uygun bir veya birkaç MÖ modeli (hipotez uzayı) seçmek.
- **4. Model Eğitimi (Training):** Seçilen modeli, hazırlanan veri setini kullanarak 'öğrenmesi' için çalıştırmak.
- **5. Model Değerlendirme (Evaluation):** Modelin daha önce görmediği yeni veriler üzerindeki performansını ölçmek.
- **6. Parametre Ayarlama (Tuning) ve Dağıtım (Deployment):** Modelin performansını iyileştirmek ve gerçek dünyada kullanılabilir hale getirmek.

MACHINE LEARNING LIFECYCLE



PROBLEM
DEFINITION

DATA PREP

MODEL SELECTION

TRAINING

DEPLOYMENT



1 Unlabeled Data

2 Data Prep

3 Model Selection

4 Training

5 Deployment

Temel Kavram: Veri Seti


Eğitim, Doğrulama ve Test

- Elimizdeki toplam veriyi genellikle üçe ayırırız:
- **Eğitim Seti (Training Set):** Modelin öğrenmek için kullandığı veri. Genellikle toplam verinin %60-80'i.
- **Doğrulama Seti (Validation Set):** Modelin farklı parametrelerini ayarlarken (tuning) performansını karşılaştırmak için kullanılır. Genellikle %10-20'si.
- **Test Seti (Test Set):** Modelin nihai performansını, tamamen 'kör' olduğu (hiç görmediği) veriler üzerinde ölçmek için kullanılır. Genellikle %10-20'si. Bu sete sadece en sonda dokunulur.


Temel Problem: Aşırı Öğrenme (Overfitting)

Ezberlemek vs. Öğrenmek


- **Aşırı Öğrenme (Overfitting):** Model, eğitim verisindeki detayları ve gürültüyü o kadar iyi öğrenir ki, yeni ve görünmeyen verilere genelleme yapma yeteneğini kaybeder. Eğitim hatası çok düşük, test hatası çok yüksektir.
- **Eksik Öğrenme (Underfitting):** Model, eğitim verisindeki temel yapıyı bile yakalayamayacak kadar basittir. Hem eğitim hem de test hatası yüksektir.
- **İyi Uyum (Good Fit):** Model, eğitim verisindeki genel deseni yakalar ve yeni verilere iyi genelleme yapar.




Under-fitting
(too simple to
explain the variance)




Appropriate-fitting




Over-fitting
(forcefitting--too
good to be true) 



Underfitted



Good Fit/Robust




Overfitted

Bias–Variance Trade-off

Genelleme Yeteneğini Dengelemek

- **Bias** (sapma): Modelin verideki karmaşıklığı yakalayamaması (underfitting).
- **Variance** (varyans): Modelin eğitime aşırı uyum sağlaması (overfitting).
- Düşük bias genelde yüksek varyansla, düşük varyans ise yüksek biasla gelir.
- **Amaç**: Hem bias hem varyansı minimize ederek en düşük toplam hatayı elde etmek.
- Çözüm stratejileri: düzenlileştirme, daha fazla veri, model karmaşıklığı ayarı, çapraz doğrulama.



Model Seçim Rehberi

Doğru Probleme Doğru Öğrenme Türü

- Problem tipine göre öğrenme yaklaşımı değişir:
 - - Etiketli veri varsa → Denetimli Öğrenme
 - - Etiket yoksa → Denetimsiz Öğrenme
 - - Ajan-çevre etkileşimi varsa → Pekiştirmeli Öğrenme
- Karar verirken veri boyutu, etiket maliyeti ve hedef türü (sayı, sınıf, ödül) dikkate alınmalıdır.
- Bu çerçeve, veri bilimi projelerinde doğru algoritma ailesini seçmek için başlangıç noktasıdır.

Data Leakage (Veri Sızıntısı)

Modelin Haksız Avantajı

- Data leakage, modelin eğitim sırasında geleceğe ait veya test verisine ait bilgiyi farkında olmadan öğrenmesidir.
- Sonuçta model eğitimde mükemmel görünür fakat gerçek dünyada başarısız olur.
- Yaygın nedenler:
 - - Eğitim/test karışımı veya yanlış zaman sıralaması
 - - Özellik mühendisliğinde hedef (label) bilgisinin sızması
 - - Normalizasyon veya ölçeklemenin tüm veri üzerinden yapılması
- Önleme: Veri ayrımını işlem öncesinde yap, tüm dönüşümleri yalnızca eğitim verisine uygula.

Haftanın Kavramları: Özet

Akılda Kalması Gerekenler

- **Makine Öğrenmesi:** Programların, kuralları verilerden öğrendiği bir YZ paradigması.
- **Denetimli Öğrenme:** Etiketli verilerle (girdi-çıktı çiftleri) öğrenme.
 - - **Sınıflandırma:** Kategorik bir çıktı tahmin etme.
 - - **Regresyon:** Sayısal bir çıktı tahmin etme.
- **Denetimsiz Öğrenme:** Etiketsiz verilerdeki gizli yapıları bulma.
- **Aşırı Öğrenme (Overfitting):** Eğitim verisini ezberleyip yeni veriye genelleme yapamama sorunu.

Gelecek Hafta: Denetimli Öğrenme - Regresyon

Teorik Dersin Konusu

- İlk makine öğrenmesi modelimiz: Lineer Regresyon.
- Bir veri setine en uygun 'çizgiyi' nasıl buluruz?
- Maliyet Fonksiyonu (Cost Function): Modelimizin ne kadar 'hatalı' olduğunu nasıl ölçeriz?
- Gradyan Azalması (Gradient Descent): Bu hatayı minimize etmek için parametreleri nasıl güncelleriz?

Düşünme Sorusu: Sınıflandırma mı, Regresyon mu?

Problemleri Kategorize Etme

- Aşağıdaki problemlerden hangisi sınıflandırma, hangisi regresyondur?
- 1. Bir müşterinin bir sonraki ay şirket web sitesinde **harçayacağı para miktarını** tahmin etmek. 
- 2. Bir tümörün iyi huylu mu yoksa kötü huylu mu **olduğunu** belirlemek. 
- 3. Bir öğrencinin fotoğrafından **yaşını** tahmin etmek. 
- 4. Bir kullanıcının bir filme 1'den 5'e kadar **vereceği puanı** tahmin etmek. 

Gerçek Dünya Örneği: Kredi Kartı Sahtekarlığı Tespiti

Dengesiz Veri Setleri Problemi

- **Problem:** Bir kredi kartı işleminin sahte mi yoksa geçerli mi olduğunu belirlemek.
- Bu bir **sınıflandırma** problemidir.
- **Zorluk:** Veri seti aşırı derecede 'dengesizdir'. Milyonlarca geçerli işleme karşılık, sadece birkaç bin sahte işlem vardır (%99.9 vs %0.1).
- Model, her şeye 'geçerli' demeyi öğrenerek %99.9 doğruluk oranına ulaşabilir, ancak hiçbir işe yaramaz.
- Bu, doğru **değerlendirme metriğini** seçmenin neden önemli olduğunu gösterir.

Özellik Mühendisliği (Feature Engineering)

Veriyi Sanata Dönüştürmek

- Ham veriyi, bir makine öğrenmesi modelinin anlayabileceği ve daha iyi öğrenebileceği 'özellikre' (features) dönüştürme sürecidir.
- Bu, genellikle bir MÖ projesinin başarısındaki en kritik faktördür.
- **Örnekler:**
 - - Bir 'tarih' sütunundan 'haftanın günü', 'ay', 'tatil mi?' gibi yeni özellikler türetmek.
 - - Metin verisinden kelime sıklıklarını çıkarmak.
 - - Kategorik verileri (örn: 'İstanbul', 'Ankara') sayısal değerlere dönüştürmek (One-Hot Encoding).
- Bu, probleme özgü bilgi ve yaratıcılık gerektirir.

Özet: Makine Öğrenmesi Felsefesi

Genelleme Sanatı

- Makine öğrenmesinin temel amacı, geçmiş verilerden öğrenerek, gelecekteki görünmeyen veriler hakkında **doğru genellemeler** yapabilen modeller oluşturmaktır.
- Bu süreç, 'ezberleme' (overfitting) ve 'yetersiz kalma' (underfitting) arasındaki hassas dengeyi bulmayı gerektirir.
- Başarı, sadece iyi bir algoritmaya değil, aynı zamanda kaliteli veriye, akıllı özellik mühendisliğine ve doğru değerlendirme metriklerine de bağlıdır.



• Sorular