



YZM0101

Yapay Zeka ve Makine Öğrenimine

Giriş

Hafta 11

Gelişmiş Sınıflandırma Modelleri

Karar Ağaçları ve Destek Vektör Makineleri (SVM)


- Geçen hafta: Lojistik Regresyon ve KNN gibi temel sınıflandırma modellerini öğrendik.
- Bu hafta: Daha güçlü, esnek ve farklı çalışma prensiplerine sahip iki önemli modeli inceleyeceğiz.
- Karar Ağaçları: Yorumlanabilirliği yüksek, kural tabanlı modeller.
- Destek Vektör Makineleri (SVM): Marjini maksimize etme fikrine dayalı güçlü ve geometrik modeller.

Karar Ağaçları (Decision Trees)

Sorular Sorarak Sınıflandırma

- Bir akış şeması (flowchart) gibi çalışan bir modeldir.
- **Yapısı:**
 - - **Kök Düğüm (Root Node):** En üstteki, tüm veri setini temsil eden düğüm.
 - - **İç Düğümler (Internal Nodes):** Veri setini bölmek için kullanılan bir özelliği ve bir soruyu (kuralı) temsil eder.
 - - **Dallar (Branches):** Sorunun cevabına göre gidilecek yolu gösterir.
 - - **Yaprak Düğümler (Leaf Nodes):** Karar sürecinin sonlandığı ve bir sınıf etiketinin atandığı düğümler.

Decision Tree Model for Car Mileage Prediction



En İyi Soruyu Nasıl Buluruz?

Veriyi En 'Saf' Hale Getirmek

- Karar ağacını oluştururken her adımda amaç, veri setini en 'saf' alt gruplara ayıracak soruyu (özellği ve eşik değeri) bulmaktır.
- 'Saflık', bir düğümdeki tüm örneklerin aynı sınıfa ait olma derecesidir.
- **Saflık Ölçütleri (Impurity Metrics):**
 - - **Gini Belirsizliği (Gini Impurity):** Bir düğümden rastgele seçilen bir örneğin, o düğümdeki dağılıma göre yanlış sınıflandırılma olasılığı.
 - - **Entropi (Entropy):** Bir düğümdeki 'düzensizliğin' veya 'belirsizliğin' bir ölçüsü. (Bilgi Teorisi'nden gelir).
- Algoritma, **Bilgi Kazancını (Information Gain)** maksimize eden, yani belirsizliği en çok azaltan soruyu seçer.

Machine learning equations for Decision tree

$$Entropy = \sum_{i=1}^C -p_i * \log_2(p_i)$$

$$Gini = 1 - \sum_{i=1}^C (p_i)^2$$

$$Gain(S, D) = H(S) - \sum_{V \in D} \frac{|V|}{|S|} H(V)$$

ID	Yaş	Gelir	Öğrenci	Kredi Notu	Satın Aldı (Y)
1	Genç	Yüksek	Hayır	Orta	Hayır
2	Genç	Yüksek	Hayır	İyi	Hayır
3	Orta	Yüksek	Hayır	Orta	Evet
4	Yaşlı	Orta	Hayır	Orta	Evet
5	Yaşlı	Düşük	Evet	Orta	Evet
6	Yaşlı	Düşük	Evet	İyi	Hayır
7	Orta	Düşük	Evet	İyi	Evet
8	Genç	Orta	Hayır	Orta	Hayır
9	Genç	Düşük	Evet	Orta	Evet
10	Yaşlı	Orta	Evet	Orta	Evet

ID	Yaş	Gelir	Öğrenci	Kredi Notu	Satın Aldı (Y)
1	Genç	Yüksek	Hayır	Orta	Hayır
2	Genç	Yüksek	Hayır	İyi	Hayır
3	Orta	Yüksek	Hayır	Orta	Evet
4	Yaşlı	Orta	Hayır	Orta	Evet
5	Yaşlı	Düşük	Evet	Orta	Evet
6	Yaşlı	Düşük	Evet	İyi	Hayır
7	Orta	Düşük	Evet	İyi	Evet
8	Genç	Orta	Hayır	Orta	Hayır
9	Genç	Düşük	Evet	Orta	Evet
10	Yaşlı	Orta	Evet	Orta	Evet

Karar Ağaçları: Avantajlar ve Dezavantajlar

Ne Zaman Kullanmalı?

- **Avantajları:**

- - **Yorumlanması Kolay:** Modelin kararlarını anlamak ve görselleştirmek basittir.
- - **Az Veri Ön İşleme:** Özellik ölçeklendirme gerektirmez. Hem sayısal hem kategorik verilerle doğal olarak çalışabilir.
- - **Doğrusal Olmayan İlişkileri Yakalar:** Karmaşık karar sınırları oluşturabilir.

- **Dezavantajları:**

- - **Aşırı Öğrenmeye (Overfitting) Eğilimli:** Ağaç çok derinleşirse, eğitim verisindeki gürültüyü ezberleyebilir.
- - **Kararsız (Unstable):** Eğitim verisindeki küçük bir değişiklik, tamamen farklı bir ağacın oluşmasına neden olabilir.

Aşırı Öğrenmeyi Önleme: Budama (Pruning)

Ağacın Karmaşıklığını Kontrol Etme


- Aşırı öğrenmeyi engellemek için ağacın büyümesini kısıtlamamız gerekir. Buna **budama** denir.
- **Yöntemler:**
 - - **Maksimum Derinlik (max_depth):** Ağacın ne kadar derine inebileceğini sınırlar.
 - - **Minimum Örnek Sayısı (min_samples_split):** Bir düğümü bölmek için gereken minimum örnek sayısını belirler.
 - - **Minimum Yaprak Boyutu (min_samples_leaf):** Bir yaprak düğümde olması gereken minimum örnek sayısını belirler.
- Bu hiperparametreler, modelin genelleme yeteneğini artırmak için ayarlanır.

Ağaç Budama (Pruning)


Overfitting'i Kontrol Altına Almak

- Karar ağaçları veri setine tamamen uyum sağlayabilir, bu da overfitting'e neden olur.
- Budama (pruning), ağacın karmaşıklığını azaltarak genelleme gücünü artırır.
- İki türü vardır: Ön Budama (pre-pruning) ve Son Budama (post-pruning).
- Ön Budama: `max_depth`, `min_samples_leaf` gibi sınırlarla büyümeyi erken durdurur.
- Son Budama: Tam ağaç kurulur, ardından gereksiz dallar doğrulama hatasına göre kesilir.

Original Decision Tree



Pruned Decision Tree (After Alpha Pruning)





Özellik Önemi (Permutation Importance)

Modeli Yorumlanabilir Hale Getirmek

- Permutation importance, her bir özelliğin model performansına katkısını ölçer.
- Yöntem: Bir özelliğin değerlerini rastgele karıştır, performans düşüşünü ölç.
- Düşüş ne kadar büyükse o özellik o kadar önemlidir.
- Model-bağımsızdır; hem ağaçlar hem de diğer algoritmalarda kullanılabilir.

Comparison of Gini and Permutation Importance






Topluluk Öğrenmesi: Rastgele Ormanlar

Birçok Ağacın Gücü Adına!

- **Fikir:** Tek bir karar ağacının kararsızlığını ve aşırı öğrenme eğilimini, birçok farklı ağaç oluşturup sonuçlarını birleştirerek gidermek.
- **Rastgele Ormanlar (Random Forests):**
 - 1. Orijinal veri setinden rastgele örneklemeler (bootstrap) alarak birçok alt veri seti oluşturur.
 - 2. Her bir alt veri seti üzerinde bir karar ağacı eğitir. Ağaçları eğitirken, her düğümde özelliklerin sadece rastgele bir alt kümesini dikkate alır.
 - 3. Tahmin yapmak için, tüm ağaçların tahminlerini alır ve çoğunluğun oyunu (sınıflandırma) veya ortalamayı (regresyon) sonuç olarak verir.

Random Forest Simplified



Random Forest Hiperparametre Analizi

Topluluğun Dengesini Kurmak

- Random Forest, birçok karar ağacının ortalamasını alarak varyansı düşürür.
- Temel hiperparametreler:
 - - `n_estimators`: Ağaç sayısı (çok olursa stabilite artar, maliyet de artar).
 - - `max_features`: Her bölünmede rastgele seçilen özellik sayısı.
 - - `oob_score`: Doğrulama için 'out-of-bag' örneklerini kullanır.
- Amaç: Yeterince fazla, ama aşırı korelasyona girmeyen ağaçlarla optimum genel performans elde etmek.



• Sorular