



YZM0101

Yapay Zeka ve Makine Öğrenimine

Giriş

Hafta 12

Denetimsiz Öğrenme (Unsupervised Learning)

Etiketlenmemiş Verideki Yapıyı Keşfetmek


- Şimdiye kadar: Denetimli Öğrenme (Regresyon, Sınıflandırma). Elimizde etiketli (y) veriler vardı.
- Şimdi: Denetimsiz Öğrenme. Elimizdeki verinin etiketleri (y) yok.
- **Amaç:** Verinin kendisinde var olan içsel yapıyı, desenleri, grupları veya anormallikleri keşfetmek.
- İki ana görev: Kümeleme (Clustering) ve Boyut Azaltma (Dimensionality Reduction).

Kümeleme (Clustering)


Verideki Doğal Grupları Bulmak

- **Görev:** Birbirine benzeyen veri noktalarını aynı gruba (kümeye), benzemeyenleri ise farklı gruplara atamak.
- **'Benzerlik'** genellikle mesafe (örn: Öklid mesafesi) ile ölçülür.
- **Uygulama Alanları:**
 - - **Müşteri Segmentasyonu:** Müşterileri satın alma davranışlarına göre gruplara ayırmak.
 - - **Görüntü Segmentasyonu:** Bir görüntüdeki pikselleri renklerine veya dokularına göre gruplayarak nesneleri ayırmak.
 - - **Anomali Tespiti:** Herhangi bir kümeye ait olmayan aykırı veri noktalarını (outliers) bulmak.

Unlabeled data



Clustered data



Average number of symptoms per week

K-Means Kümeleme Algoritması

En Popüler Kümeleme Yöntemi

- **Amaç:** Veri setini, önceden belirlenmiş **K** adet kümeye bölmek.
- **Fikir:** Her kümenin bir **merkez noktası (centroid)** vardır. Her veri noktası, kendisine en yakın olan merkez noktasının kümesine aittir.
- Algoritma, bu merkez noktalarının en uygun yerini bulmaya çalışır.
- **'En uygun yer':** Tüm veri noktalarının kendi küme merkezlerine olan uzaklıklarının kareleri toplamını (WCSS) minimize eden yerdir.

K-Means Algoritmasının Adımları

Merkezleri Hareket Ettirmek

- ****1. Başlatma:**** K adet küme merkezini (centroid) rastgele konumlara yerleştir.
- ****2. Atama Adımı:**** Her bir veri noktasını, kendisine en yakın olan küme merkezinin kümesine ata.
- ****3. Güncelleme Adımı:**** Her bir küme için, o kümeye atanan tüm veri noktalarının ortalamasını alarak küme merkezinin yerini güncelle (merkezi, kümenin yeni ağırlık merkezine taşı).
- ****4. Tekrarlama:**** Küme merkezlerinin konumu artık değişmeyene (veya çok az değişene) kadar 2. ve 3. adımları tekrarla.

Soru

Öğrenci No	Çalışma Saati (X)	Vize Notu (Y)	Final Notu (Z)
P1	8	90	85
P2	9	95	90
P3	7	85	80
P4	8.5	92	92
P5	2	40	35
P6	3	45	45
P7	1	35	30
P8	2.5	42	40
P9	5	65	60
P10	6	70	65
P11	5.5	68	62
P12	4.5	60	58

Veri setini K=2 için K-Means algoritmasıyla kümeleyin (Başlangıç merkezleri: P1 ve P5).


Veri setini K=3 için K-Means algoritmasıyla kümeleyin (Başlangıç merkezleri: P1, P5 ve P9).

K Seçimi: Dirsek ve Silhouette Yöntemleri

Doğru Küme Sayısını Belirlemek

- K-Means, kullanıcıdan önceden K değerini ister; yanlış seçim hem yorum hem performans açısından sorun yaratır.
- Dirsek (Elbow) yöntemi: K artarken 'inertia' (toplam iç-küme varyansı) azalır; azalış hızının kesildiği nokta optimum K'dır.
- Silhouette skoru: Her örneğin kendi kümesine benzerliği ve diğer kümelere uzaklığı arasındaki farkın ortalamasıdır $(-1 - 1)$.
- Yüksek silhouette skoru, net biçimde ayrılmış kümeler anlamına gelir.

Elbow Method For Optimal k



Line plot between K and inertia

k-means++ Başlangıç Stratejisi

Daha Kararlı Kümeleme Sonuçları

- Rastgele merkez seçimi kötü sonuçlar veya tekrarlanamazlık yaratabilir.
- k-means++ algoritması merkezleri akıllıca seçerek yakınsama hızını artırır.
- İlk merkez rastgele seçilir; sonraki merkezler, mevcut merkezlere uzaklıklarının karesiyle orantılı olasılıkla seçilir.
- Avantaj: Tekrarlı çalıştırmalarda daha kararlı ve düşük toplam hata değerleri.

Boyut Azaltma (Dimensionality Reduction)



Daha Azıyla Daha Çoğunu Anlamak

- ****Amaç:**** Bir veri setindeki özellik (sütun) sayısını, en önemli bilgileri koruyarak azaltmak.
- ****Neden Önemli?****
 - - ****Görselleştirme:**** Yüksek boyutlu veriyi 2D veya 3D'ye indirgeyerek insan tarafından anlaşılabilir hale getirmek.
 - - ****Hesaplama Verimliliği:**** Daha az özellik, makine öğrenmesi modelleri daha hızlı eğitilir.
 - - ****Gürültü Azaltma:**** Önemsiz veya gürültülü özellikleri kaldırarak model performansını artırabilir (Boyutluluk Laneti - Curse of Dimensionality).

Temel Bileşen Analizi (Principal Component Analysis - PCA)

Verideki Maksimum Varyans Yönlerini Bulmak

- En yaygın kullanılan boyut azaltma tekniğidir.
- ****Fikir:**** Veri setindeki en büyük varyansın (değişimin, yayılımının) olduğu yönleri bulur. Bu yönlere ****Temel Bileşenler (Principal Components)**** denir.
- İlk temel bileşen, verideki en büyük varyansı yakalayan yöndür.
- İkinci temel bileşen, birinciye dik olan ve geri kalan varyansın en büyüğünü yakalayan yöndür.
- Veriyi, bu yeni temel bileşen eksenleri üzerine 'projekte ederek' (izdüşümünü alarak) boyutunu azaltır.



PCA'in Adımları (Sezgisel)

Yeni Eksenler Yaratmak

- ****1. Veriyi Ölçeklendirme:**** PCA, varyansa dayalı olduğu için, başlamadan önce tüm özelliklerin aynı ölçekte olması ****çok önemlidir****. (StandardScaler kullanılır).
- ****2. Kovaryans Matrisini Hesaplama:**** Özelliklerin birbirleriyle nasıl birlikte değiştiklerini (kovaryans) ölçen bir matris oluşturur.
- ****3. Özvektörleri ve Özdeğerleri Bulma:**** Kovaryans matrisinin özvektörleri, temel bileşenlerin (yeni eksenlerin) yönünü, özdeğerleri ise bu yönlerdeki varyansın büyüklüğünü (önemini) verir.
- ****4. Temel Bileşenleri Seçme:**** En büyük özdeğerlere sahip olan ilk 'k' adet özvektörü (temel bileşeni) seçeriz.
- ****5. Veriyi Dönüştürme:**** Orijinal veriyi, bu seçilen 'k' adet temel bileşen üzerine projekte ederiz.

Standardizasyonun PCA Üzerindeki Etkisi

Ölçeklenmezse Yanıltıcı Bileşenler

- PCA, varyansı en yüksek yönleri bulur; büyük ölçekli özellikler küçükleri bastırabilir.
- Özellikleri standardize etmek (ortalama = 0, std = 1) tüm değişkenleri eşit katkılı hale getirir.
- Standardizasyon yapılmadığında, PCA büyük ölçekteki değişkenlerin eksenlerine yönelir.
- Bu durum, boyut indirgeme yerine yanlış yönelimli bir dönüşüm yaratır.

Açıklanan Varyans ve Bileşen Seçimi

Kaç Boyut Tutulmalı?

- Her PCA bileşeni toplam varyansın bir kısmını açıklar.
- Açıklanan varyans oranı (explained variance ratio) toplam varyansa göre katkıyı gösterir.
- Kümülatif varyans %90–95’e ulaşana kadar bileşen sayısı genellikle yeterli kabul edilir.
- Bu analiz, hem boyut indirgeme miktarını hem bilgi kaybını dengelemeyi sağlar.

t-SNE ve UMAP ile Görselleştirme

Yüksek Boyutu Anlamlı Görünür Hale Getirmek

- t-SNE (t-Distributed Stochastic Neighbor Embedding) ve UMAP, yüksek boyutlu veriyi 2-3D'de sezgisel olarak gösterir.
- Amaç: Benzer örnekleri yakın, farklıları uzak konumlamak.
- t-SNE yerel ilişkileri korur, UMAP hem yerel hem küresel yapıyı daha iyi korur.
- PCA genellikle ilk adım olarak boyutu küçültmek için, t-SNE/UMAP son adımda görselleştirme için kullanılır.

Anomali Tespiti (Outlier Detection) Tanıtımı

Kümelerin Dışında Kalanları Bulmak

- Kümeleme, normal örüntüleri tanımlar; bu sayede dışarıda kalan noktalar 'anomali' olarak belirlenebilir.
- Basit yöntemler: Z-score (ortalama $\pm 3 \sigma$), IQR ($Q3 + 1.5 \times IQR$ üstü).
- İleri yöntemler: Isolation Forest, Local Outlier Factor, One-Class SVM.
- Anomali tespiti, üretim hataları, siber saldırılar, sahtekârlık gibi alanlarda kullanılır.

Haftanın Kavramları: Özet

Akılda Kalması Gerekenler

- ****Denetimsiz Öğrenme:**** Etiketlenmemiş verideki içsel yapıyı ve desenleri keşfetme.
- ****Kümeleme:**** Benzer veri noktalarını gruplara ayırma görevi.
- ****K-Means:**** Veriyi K adet kümeye, küme merkezlerine olan uzaklığı minimize ederek ayıran bir algoritma.
- ****Centroid:**** Bir kümedeki noktaların ortalama konumu, yani küme merkezi.
- ****Boyut Azaltma:**** Verinin içerdiği bilgiyi koruyarak özellik sayısını azaltma tekniği.
- ****PCA:**** Verideki maksimum varyans yönlerini (temel bileşenleri) bularak boyut azaltan bir algoritma.

Gelecek Hafta: Yapay Sinir Ağları (YSA)

Teorik Dersin Konusu

- Derin Öğrenmenin temel taşı: Yapay Sinir Ağları.
- Biyolojik nöronlardan ilham alan yapı: Perceptron.
- Çok Katmanlı Perceptron (Multi-Layer Perceptron - MLP): Katmanlar, nöronlar ve aktivasyon fonksiyonları.
- Öğrenme Süreci: Geri Yayılım (Backpropagation) algoritmasının sezgisel anlatımı.
- Derin Öğrenme nedir? YSA'dan Derin Sinir Ağlarına (DNN) geçiş.

.

Düşünme Sorusu: K-Means ve Ölçeklendirme

Veri Ön İşlemenin Önemi

- Bir müşteri veri setiniz olduğunu ve iki özelliğiniz olduğunu düşünün:
- - ****Özellik A:**** Müşterinin yıllık geliri (örn: 50,000 - 250,000 TL aralığında).
- - ****Özellik B:**** Müşterinin son bir ayda yaptığı alışveriş sayısı (örn: 1 - 50 aralığında).
- Bu veri setine, özellikleri ****ölçeklendirmeden**** doğrudan K-Means uygularsanız ne olur?
- Algoritmanın mesafe hesaplamaları nasıl etkilenir? Hangi özellik, kümelemeyi daha fazla domine eder? Neden?
-

Gerçek Dünya Örneği: Tavsiye Sistemleri

Boyut Azaltma ile Ortak Zevkleri Keşfetmek

- Netflix veya Spotify gibi platformlar, kullanıcılara yeni içerikler önermek için tavsiye sistemleri kullanır.
- ****Problem:**** Binlerce film/şarkı (özellik) ve milyonlarca kullanıcı (örnek) içeren devasa bir matris.
- ****Boyut Azaltmanın Rolü:**** PCA'nın bir uzantısı olan SVD (Singular Value Decomposition) gibi teknikler, bu devasa matrisin boyutunu azaltmak için kullanılır.
- Bu teknikler, filmlerin/şarkıların altında yatan gizli 'türleri' veya 'konseptleri' (örn: 'aksiyon-bilimkurgu', 'romantik-komedi') otomatik olarak keşfeder.
- Bir kullanıcının bu gizli türlere olan ilgisi, ona yeni tavsiyeler yapmak için kullanılır.



• Sorular