



YZM0101

Yapay Zeka ve Makine Öğrenimine


Giriş

Hafta 13


Yapay Sinir Ağlarına Kavramsal ve Tarihsel Bir Bakış

İnsandan İlham Alan Öğrenme Sistemleri

- Yapay sinir ağları (YSA), insan beyninin nöron yapısından esinlenilerek geliştirilmiş hesaplama modelleridir.
- Amaç, deneyimden öğrenebilen ve genelleme yapabilen sistemler oluşturmaktır.
- Tarihçe: 1943'te McCulloch–Pitts nöron modeli, 1958'de Rosenblatt'ın Perceptron'u, 1986'da Backpropagation devrimi.
- Modern dönemde derin öğrenme, büyük veri ve GPU hesaplama gücü sayesinde yeniden yükselişe geçmiştir.




S. McCulloch – W. Pitts



- Adjustable Weights
- Weights are not Learned



F. Rosenblatt




- Learnable Weights and Threshold



B. Widrow – M. Hoff




M. Minsky – S. Papert



- XOR Problem




D. Rumelhart – G. Hinton – R. Williams



- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting




V. Vapnik – C. Cortes



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



G. Hinton – S. Ruslan



- Hierarchical feature Learning

Yapay Sinir Ağları ve Tarihçesi


1950'lerde beyin elektron mikroskobu ile incelenmekte

100 Milyar nörondan oluşmakta,

100 Trilyon sinaps bağlantısı

Beyin enerji verimliliği yüksek

10^{-16} joules per operation



Yapay Sinir Ağları ve Tarihçesi

Single Layer Perceptron XOR problem!!!

1980'ler MLP nonlinear problemler için önerildi


David Rumelhart, Geoffrey Hinton ve Ronald Williams BackPropagation algoritmasının 1986'da önermişlerdir

İkinci bahar ve popülerleşme

İkinci YZ kışı 1990 ortalarına kadar



Aşırı beklenti

Maliyet



Yapay Sinir Ağları ve Tarihçesi

- Hochreiter 1991, Bengio 1994 long sequence problem
- Hochreiter ve Schmidhuber 1997 LSTM
- İlk CNN algoritması ve uygulamaları Yann LeCun 1998
- 1990 Vapnik tarafından SVM




Yapay Nöronun Matematiksel Modellemesi

Ağırlıklı Girdi, Bias ve Aktivasyon

- Her nöron, birden fazla girdi ($x_1, x_2, \dots, x_n$) alır ve her birine bir ağırlık ($w_1, w_2, \dots, w_n$) uygular.
- Net girdi: $z = \sum(w_i \cdot x_i) + b$
- Çıktı: $y = f(z)$, burada f aktivasyon fonksiyonudur.
- Bias terimi, karar sınırının orijinden kaymasını sağlar; modelin esnekliğini artırır.

Yapay Sinir Ağlarına Giriş


McCulloch-Pitts Nöron Modeli



Yapay Sinir Ağlarına Giriş

Örnek: Logic AND



x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1



Yapay Sinir Ağlarına Giriş

Örnek: Logic AND



x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1



Yapay Sinir Ağlarına Giriş

Örnek: Logic OR



x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	1



Yapay Sinir Ağlarına Giriş

Örnek: Logic OR


x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	1



Yapay Sinir Ağlarına Giriş


Örnek: Logic NOT

x_1	y
0	1
1	0




Yapay Sinir Ağlarına Giriş

Örnek: Logic NAND



Yapay Sinir Ağlarına Giriş

Perceptron



$$y = \varphi \left(\sum_{i=1}^n w_i x_i - \theta \right)$$
$$y = \varphi \left(\sum_{i=1}^{n+1} w_i x_i \right)$$
$$y = \varphi(\bar{w}^T \bar{x})$$

$$\bar{w} = \begin{bmatrix} w_1 \\ \vdots \\ w_{n+1} \end{bmatrix} \in \mathbb{R}^{n+1} \quad \bar{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_{n+1} \end{bmatrix} \in \mathbb{R}^{n+1}$$

Aktivasyon Fonksiyonlarının Rolü ve Türleri

Doğrusal Olmayanlıkla Öğrenmeyi Güçlendirmek

- Sigmoid: $f(z) = 1/(1 + e^{(-z)})$, olasılık çıktısı sağlar.
- Tanh: $f(z) = (e^z - e^{(-z)}) / (e^z + e^{(-z)})$, veri merkezlenir.
- ReLU: $f(z) = \max(0, z)$, gradyan kaybolma sorununa dirençlidir.
- Leaky ReLU ve ELU: ReLU'nun sıfır bölgesinde bilgi kaybını azaltır.

Yapay Sinir Ağlarına Giriş

Activation function


Genellikle aktivasyon fonksiyonları squashing (sıkıştırma) amaçlı olan yapılarda kullanılmaktadır.

$$\varphi(.): \mathbb{R} \rightarrow [0,1] \text{ or } (0,1)$$

$$\varphi(.): \mathbb{R} \rightarrow [-1,1] \text{ or } (-1,1)$$

1) Unipolar Threshold Function (Hard-Limiter):

$$\varphi(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$




Yapay Sinir Ağlarına Giriş

Activation function


2) Bipolar Threshold Function (Signum Function):

$$\varphi(x) = \begin{cases} 1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$



3) Unipolar Piecewise Linear Sigmoid:

$$\varphi(x) = \begin{cases} 1, & x \geq 1/2 \\ x + \frac{1}{2}, & -\frac{1}{2} < x < \frac{1}{2} \\ 0, & x \leq -1/2 \end{cases}$$




Yapay Sinir Ağlarına Giriş

Activation function

4) Bipolar Piecewise Linear Sigmoid:

$$\varphi(x) = \begin{cases} 1, & x \geq 1/2 \\ x + \frac{1}{2}, & -\frac{1}{2} < x < \frac{1}{2} \\ 0, & x \leq -1/2 \end{cases}$$




Yapay Sinir Ağlarına Giriş

Activation functions used frequently


1) Sigmoid:

$$\varphi(x) = \frac{1}{1 + e^{-x}}$$



2) Tanh:

$$\varphi(x) = \frac{1 - e^{-x}}{1 + e^{-x}} = \frac{2}{1 + e^{-x}} - 1$$




Yapay Sinir Ağlarına Giriş

Activation functions used frequently


3) ReLU:

$$\varphi(x) = \max(0, x)$$




4) Exponential Linear Unit (ELU):

$$\varphi(x) = \begin{cases} x, & x > 0 \\ \alpha * \exp^x - 1, & x < 0 \end{cases}$$



Yapay Sinir Ağlarına Giriş

Activation functions used frequently




İleri Yayılım (Forward Propagation) Mekanizmasının Katmansal Analizi

Veri Akışı ve Katmanlar Arası Hesaplama

- Her katman, bir önceki katmanın çıktısını giriş olarak alır.
- Hesaplama: $z^{(l)} = W^{(l)} \cdot a^{(l-1)} + b^{(l)}$
- Aktivasyon: $a^{(l)} = f(z^{(l)})$
- Son katmanın çıktısı modelin tahminidir ($\hat{y}$).


Yapay Sinir Ağlarına Giriş

A Simplified Diagram for Perceptron



Yapay Sinir Ağlarına Giriş

A Single Layer Perceptron



Yapay Sinir Ağlarına Giriş

A Single Layer Perceptron



$$\begin{aligned}\bar{x} &= \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n \\ \bar{w}_i &= \begin{bmatrix} w_{i1} \\ \vdots \\ w_{in} \end{bmatrix} \in \mathbb{R}^n \\ \bar{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} &= \begin{bmatrix} \varphi_1(\bar{w}_1^T \bar{x}) \\ \vdots \\ \varphi_m(\bar{w}_m^T \bar{x}) \end{bmatrix} \in \mathbb{R}^m\end{aligned}$$

$$\begin{aligned}\Gamma &= \begin{bmatrix} \varphi(.) & 0 & \dots & 0 \\ 0 & \varphi(.) & \dots & \vdots \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & \varphi(.) \end{bmatrix} \\ W &= \begin{bmatrix} \bar{w}_1^T \\ \bar{w}_2^T \\ \vdots \\ \bar{w}_m^T \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & \dots & w_{1n} \\ w_{21} & w_{22} & \dots & \vdots \\ \vdots & \vdots & \dots & \vdots \\ w_{m1} & w_{m2} & \dots & w_{mn} \end{bmatrix} \\ \bar{y} &= \Gamma(W\bar{x})\end{aligned}$$

Yapay Sinir Ağlarına Giriş

Perceptron Example (XOR):

x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0



$$H_1: -x_1 + x_2 - 0.5 = 0$$

$$H_2: x_1 - x_2 - 0.5 = 0$$


$$W = \begin{bmatrix} -1 & 1 & 0.5 \\ 1 & -1 & 0.5 \end{bmatrix}$$

$$\bar{x} = [x_1 \quad x_2 \quad -1]$$

Yapay Sinir Ağlarına Giriş

Perceptron Example (XOR):

x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0



$$H_1: -x_1 + x_2 - 0.5 = 0$$

$$H_2: x_1 - x_2 - 0.5 = 0$$

$$W = \begin{bmatrix} -1 & 1 & 0.5 \\ 1 & -1 & 0.5 \end{bmatrix}$$

$$\bar{x} = [x_1 \quad x_2 \quad -1]$$

OR


Kayıp Fonksiyonlarının Matematiksel Tanımı

Tahmin Hatasını Nicel Olarak Ölçmek

- Kayıp fonksiyonu, gerçek değer (y) ile tahmin ($\hat{y}$) arasındaki farkı ölçer.
- Regresyon için MSE: $L = \frac{1}{2} (y - \hat{y})^2$
- Sınıflandırma için Cross-Entropy: $L = -\sum y_i \log(\hat{y}_i)$
- Amaç: L 'yi minimize edecek ağırlıkları bulmak.

Yapay Sinir Ağlarına Giriş

MultiLayer Perceptron



Yapay Sinir Ağlarına Giriş

MultiLayer Perceptron

$$\begin{aligned}W_1 &= \mathbb{R}^{q \times n} \\W_2 &= \mathbb{R}^{m \times q}\end{aligned}$$


$$\bar{y} = \Gamma(W_2 \bar{z}) = \Gamma(W_2 \Gamma(W_1 \bar{x}))$$

Çok daha fazla katman için:

$$\bar{y} = \Gamma(W_2 \bar{z}) = \Gamma(W_k \Gamma(W_{k-1} \Gamma(W_{k-2} \dots \Gamma(W_1 \bar{x})))) \dots)$$

Yapay Sinir Ağlarına Giriş

Problems:





• Sorular